

# Identifikasi Sars-CoV-2 dengan Large Dataset Pasien CT-Scan Menggunakan Pendekatan Metode CNN

Muhammad Ilham Malik

Universitas Pendidikan Indonesia  
Departemen Pendidikan Ilmu Komputer  
[muh.ilham.malik@upi.edu](mailto:muh.ilham.malik@upi.edu)

**Abstrak**— Penyakit covid-19 yang disebabkan oleh infeksi virus Sars-CoV-2 telah menyebar ke seluruh dunia sejak tahun 2020 dan masih berlanjut hingga saat ini. Sudah banyak penelitian yang telah dilakukan, salah satunya adalah observasi pada pola gambar computer tomography(CT) pasien yang didiagnosis terinfeksi Sars-CoV-2. Oleh karena itu, dalam penelitian ini kami membangun sebuah model sebagai upaya mengidentifikasi pola gambar CT-scan pasien yang terinfeksi Sars-CoV-2. Data yang digunakan dalam pembangunan model ini berasal dari penelitian yang dilakukan oleh Angelov et al. [4] Model yang dibangun menggunakan metode convolutional neural network(CNN) berbasis python menggunakan library tensorflow. Hasil penelitian dari model ini memiliki performa yang cukup tinggi dan lebih baik dibandingkan dengan pre-trained model seperti VGG16, Resnet, dll.

**Kata kunci**— klasifikasi citra digital, deep learning, computer vision.

## I. PENDAHULUAN

Corona Virus Disease(COVID) pertama kali muncul pada tahun 2019 di Wuhan, ibu kota Provinsi Hubei. Pada tanggal 30 Januari 2020, World Health Organization(WHO) mendeklarasikan

pandemic akan penyakit COVID [1][2][3]. Diakumulasikan bahwa jumlah kumulatif kasus terkonfirmasi sebanyak 305,191,603 dan kasus terkonfirmasi meninggal sebanyak 5,484,782 jiwa[5].

Banyak temuan penelitian yang telah dilakukan, salah satunya adalah observasi pada pola gambar computer tomography(CT) pasien yang didiagnosis terinfeksi Sars-CoV-2, sebagai analisis di masa yang akan datang. Sebanyak 40 dari 41 pasien di Wuhan yang terinfeksi, terungkap bahwa terdapat kekeruhan pada paru-paru[6]. Temuan lain menemukan tingginya rasio paru putih dengan bentuk morfologi melengkung [7]. Proses deteksi dan diagnosa yang cepat dari penyakit ini merupakan sebuah usaha yang tidak ternilai untuk memastikan pertolongan pada waktu yang tepat.

Pada paper ini, penelitian menggunakan data yang telah dibuat publik oleh Angelov et al. [4]. Data ini terdiri dari 1252 gambar CT-scans yang berasal dari pasien terinfeksi virus Sars-CoV-2 dan sebanyak 1229 gambar CT-scans yang tidak terinfeksi dengan virus Sars-CoV-2. Penelitian sebelumnya yang dilakukan oleh Angelov et al.[4] menggunakan pendekatan metode *deep learning* yang dinamai *eXplainable deep learning method(xDNN)*. Hasil yang diperoleh dari penelitian tersebut yaitu perolehan performa model

identifikasi dari data Sars-CoV-2 CT-scans yang cukup tinggi. Oleh karena itu, kami mencari pendekatan lain yaitu menggunakan metode *convolutional neural network*(CNN) berbasis python yang memiliki performa lebih baik pada evaluasi *recall* jika dibandingkan dengan penelitian sebelumnya. Pembanding dasar yang digunakan pada paper ini meliputi model *pre-trained* seperti VGG16[21], ResNet[22], GoogleNet, AlexNet[20].

Struktur paper ini disusun sebagai berikut, pada bagian II menjelaskan keterhubungan dengan penelitian sebelumnya. Bagian III menjelaskan model identifikasi *real* data CT-scan menggunakan pendekatan CNN berbasis python yang diajukan. Bagian IV mempresentasikan hasil performa eksperimen model yang dilakukan menggunakan matriks evaluasi. Bagian V kesimpulan yang dihasilkan dari paper ini.

## II. STUDI LITERATUR

Dalam upaya memahami pendekatan *convolutional neural network*(CNN) dapat dimulai pada komponen-komponen dasar.

### A. Image Classification

Permasalahan klasik yang ada pada bidang *computer vision* adalah cara menentukan apakah suatu data citra digital memiliki objek spesifik, fitur, atau aktivitas. Berbagai macam permasalahan tersebut dirangkum pada literatur ini[17].

*Object recognition* dapat disebut juga *object classification* mampu mengenali satu atau lebih kelas objek melalui proses *training*.

*Identification* mendeteksi sebuah instansi yang terdapat dari sebuah objek. Sebagai contoh proses mengenali wajah seseorang atau *fingerprint* seseorang.

*Detection* data citra digital yang dilatih untuk kondisi tertentu. Sebagai contoh pendeteksian kemungkinan munculnya sel abnormal yang berasal dari gambar medis.

### B. Convolution Neural Network(CNN)

Dalam *deep learning*, *convolutional neural network* dapat disebut CNN atau ConvNet adalah sebuah kelas dari jaringan saraf tiruan(*artificial neural network*) yang pada umumnya diaplikasikan untuk menganalisis citra digital[9]. CNN juga dikenal sebagai *shift invariant*, berdasarkan arsitektur *shared-weight* dari kernel konvolusi[24] atau disebut *filter* yang bergeser sepanjang fitur masukan dan melakukan respons operasi translasi equivariant biasa disebut *feature maps*[10][11]. Secara *counter intuitive* kebanyakan CNN hanya equivariant [12]. CNN diaplikasikan pada beberapa bidang seperti *image and video recognition*, *recommender systems*[13], *image classification*, *image segmentations*, *medical image analysis*, Pengolahan citra digital(*Natural image processing*)[14], *brain-computer interfaces*[15] dan *financial time-series*[16].

CNN merupakan bentuk dari *multilayer perceptrons*(MLP) yang teratur. MLP pada umumnya berarti jaringan yang terhubung secara keseluruhan sebagaimana hingga setiap neuron yang terdapat pada layer dapat terhubung pada neuron di layer selanjutnya. Hal ini menyebabkan jaringan tersebut rentan atau rawan dengan *overfitting* data. Solusi dalam menyelesaikan permasalahan tersebut pada umumnya dapat melalui *penalize* parameter selama *training* atau dapat mematikan beberapa neuron(*dropout*). CNN sendiri menggunakan pendekatan lain dalam regularisasi, CNN memanfaatkan pola hirarki yang ada pada data dan

memasangkan pola-pola rumit yang diperoleh dari pola yang lebih kecil dan sederhana dihasilkan dari proses *filtering*.

CNN terinspirasi dari proses biologis dimana keterhubungan antar neuron menggambarkan organisasi dari *visual-cortex* manusia. Dibandingkan dengan algoritma klasifikasi citra digital lain, CNN mengoptimalkan *filter* melalui pembelajaran secara otomatis, jika pada algoritma lain *filter* yang digunakan untuk algoritma tersebut merupakan turunan rumusan yang dibuat oleh manusia atau tetap.

Berdasarkan literatur klasifikasi sistem citra digital berbasis pendekatan metode *convolutional neural network* menunjukkan hasil rasio deteksi sebesar 81.6% dari 120 data latih.[23]

### C. eXplainable Deep Learning(xDNN)[2]


Sebuah prototipe berbasis pembelajaran merupakan inti dari xDNN. Prototipe merupakan sampel data *training* yang asli dan sangat representatif. Pada penelitian yang dilakukan oleh Angelov et al.[4] mengajukan sebuah model prototype yang dideskripsikan pada paper [4], lalu dengan objek sampel citra digital yang dikonversikan ke dalam bentuk fitur vektor menggunakan *transfer learning*. Pada paper tersebut disebutkan bahwa peneliti menggunakan vektor berukuran 4096 yang dibentuk dari layer yang terhubung secara keseluruhan pada model VGG-16[21].

## III. METODE


### A. Deskripsi Dataset

Data yang digunakan terdiri dari 2481 citra digital CT-scan, sebanyak 1252 untuk pasien yang terinfeksi Sars-CoV-2 dan 1229 untuk yang tidak terinfeksi Sars-CoV-2, namun mereka yang dipresentasikan memiliki penyakit paru-paru lain. Dataset

ini diperoleh dari sebuah rumah sakit yang berada di Sao Paulo, Brazil. Secara rinci jumlah pasien diilustrasikan oleh gambar 1 dan citra digital pada gambar 2[4].



**Gambar 1.** Ilustrasi jumlah pasien berdasarkan jenis kelamin

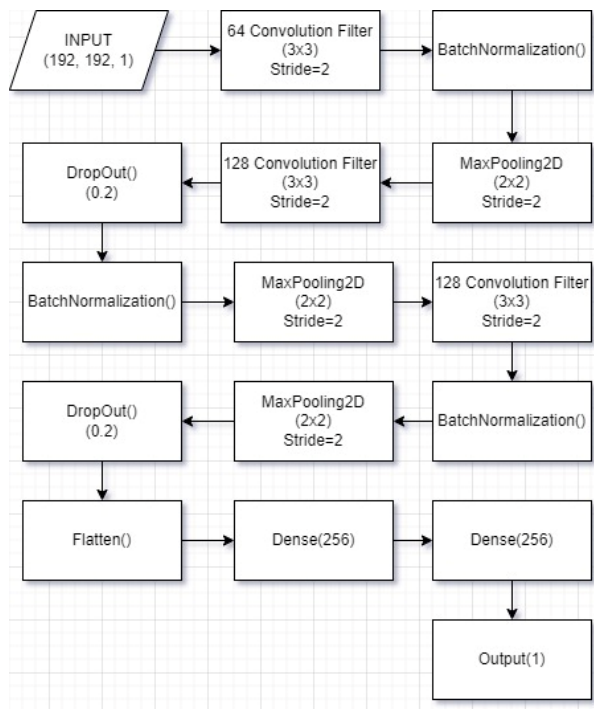


**Gambar 2.** Sampel dataset CT-scan

### B. Metode Model

Pada paper ini metode pendekatan yang digunakan adalah metode *convolutional neural network*(CNN). CNN terinspirasi dari cara kerja otak pada bagian korteks visual manusia. Salah satu kesuksesan dari penggunaan metode ini adalah keberadaan dari dataset yang besar,

lalu kemampuan dari CNN yang dapat mempelajari fitur citra digital secara implisit [19] sebagaimana telah dijelaskan pada bagian II. Model ini dibangun dengan menggunakan bahasa pemrograman python dan library tensorflow. Pendekatan yang kami lakukan terdiri dari tujuh tahap utama diantaranya adalah konvolusi[24], *batch normalization*, *max pooling*, *dropout*, *flatten*, dan *output* selengkapnya dapat dilihat pada gambar 2.



**Gambar 3.** Model CNN yang Diajukan

Tahap *preprocessing* yang dilakukan pertama kali adalah ketika pembacaan citra digital dipastikan citra digital dirubah ukuran dan warna menjadi 192x192 dengan format warna *grayscale*. Hal ini dilakukan karena jika menggunakan ukuran citra digital asli ukurannya terlalu besar yang mengakibatkan komputasi menjadi mahal dan *training model* lebih lama. Penggunaan ukuran 192x192 dipilih karena citra digital akan banyak dikonvolusi[24] dan *pooling* sehingga ukurannya akan semakin kecil, dengan ukuran citra digital tersebut

memastikan bahwa informasi fitur penting tidak hilang saat tahap proses *training* berlangsung.

Setelah citra digital dibaca maka citra digital disimpan ke dalam *np.array*. Seluruh citra digital tersebut dinormalisasikan dengan rumus normalisasi pada gambar 3.

$$z = \frac{x - \min(x)}{\max(x) - \min(x)}$$

**Gambar 4.** Rumus Normalisasi

Tahap pertama, citra digital yang telah diproses sebelumnya dimasukan dan dikonvolusikan[24] dengan ukuran matriks 3x3 ke seluruh 64 neuron yang terdapat pada layer pertama. Pada layer pertama juga terdapat sebuah *activation function Rectified Linear Unit*(ReLU), jika output yang dihasilkan memiliki nilai positif maka akan tetap melempar nilai tersebut, namun jika nilai yang di-output merupakan nilai negatif maka akan dilempar nilai 0. Selanjutnya setelah dikonvolusikan[24], tahap kedua yaitu melakukan sebuah *method* bernama *BatchNormalization()* *method* ini digunakan untuk memastikan bahwa nilai output yang dihasilkan dari konvolusi[24] sebelumnya tidak melebihi nilai 1. Tahap selanjutnya citra digital dimasukan ke dalam layer *maxpooling2d()*, pada layer ini citra digital akan di-*downsampling*. Secara sederhana tahap berikutnya hingga sebelum layer *Dense()* hanya terdiri konvolusi[24] dan *maxpooling2d()* yang diulang kembali sebanyak dua kali.

Layer-layer lain yang belum disebutkan adalah layer *DropOut()*, layer ini berfungsi sebagai pemotong *neuron* agar neuron tersebut tidak dilalui saat *training*.

Hal ini dilakukan supaya menghindari dari hasil performa model yang *overfitting*. *Overfitting* terjadi ketika model yang dibuat hanya mengingat data dan tidak dapat meregulasi data yang diberikan. Selain itu terdapat juga layer *flatten()* bekerja sebagai perubah sebuah citra digital yang pada kasus ini memiliki bentuk 2 dimensi menjadi tipe data vektor atau 1 dimensi. Hal ini dilakukan karena layer *Dense()* tidak dapat menerima masukan data multidimensional.

Selanjutnya pada dua layer terakhir diterapkan layer *Dense()* dengan masing-masing ukuran 256 neuron. Layer terakhir merupakan sebuah layer *Dense()* dengan ukuran 1 neuron. Hal ini dilakukan karena data label yang diolah menggunakan *LabelBinarizer()* dimana output hanya 0 dan 1. Fungsi aktivasi yang digunakan merupakan fungsi sigmoid.

Pada proses *training data* memiliki parameter sebagai berikut.

- Jumlah *epochs* : 80
- Loss : *Binary Crossentropy*
- *Learning rate(epoch#1~20)* : 0.0001
- *Learning rate(epoch#21~40)* : 0.00001
- *Learning rate(epoch#41~60)* : 0.000001
- *Learning rate(epoch#61~80)* : 0.000001

#### IV. HASIL

Hasil performa yang diperoleh dari model pendekatan CNN untuk identifikasi yang diberi dataset Sars-CoV-2 yang diajukan akan dibandingkan dengan model yang diajukan pada paper peneliti sebelumnya[4] dan dengan model-model *pre-trained* sebagai acuan batas dasar. Tahap pembagian data untuk *training* menggunakan metode split data dengan rasio 80:20, dimana 80% data merupakan data training dan 20% data sebagai data test. Rasio pembagian data tersebut diaplikasikan ke seluruh model.

Metric Method	Accuracy	Precision	Recall	F1 Score
xDNN[4]	97.38%	99.16%	95.53%	97.31%
ResNet[22]	94.96%	93.00%	97.15%	95.03%
GoogleNet	91.73%	90.20%	93.50%	91.82%
VGG-16[21]	94.96%	94.02%	95.43%	94.97%
AlexNet[20]	93.75%	94.98%	92.28%	93.61%
TFModel	96.78%	94.30%	97.78%	95.94%

**Tabel 1.** Hasil perbandingan performa berdasarkan *metrics evaluation*

Berdasarkan table 1, model yang diajukan atau dijadikan sebagai eksperimen ditandai dengan nama TFModel (*Tensorflow model*). Berdasarkan hasil yang ditampilkan dari tabel 1, TFModel memiliki performa yang cukup tinggi. Hal

ini ditandai dengan nilai keempat *evaluation metrics* yang dimiliki TFModel lebih tinggi dibandingkan model *pre-trained* yang dijadikan sebagai acuan. Namun, pada *precision* TFModel memiliki selisih sebesar 0.68% dibandingkan dengan

model *pre-trained* AlexNet[20]. Selain itu model yang diajukan oleh peneliti sebelumnya[4] yang ditandai xDNN masih menjadi model terbaik. Hampir seluruh *evaluation metrics* seperti *accuracy*, *precision*, dan *F1-score* lebih unggul dibandingkan dengan *pre-trained model* dan model yang diajukan(TFModel). Namun TFModel memiliki performa *recall* yang lebih baik dibandingkan dengan xDNN. Perbedaan tersebut cukup signifikan sebesar 2.25%.

## V. KESIMPULAN

Paper ini mengambil dataset yang sebelumnya telah diteliti [4], dataset ini memiliki data sebanyak 2481 citra digital CT-scans yang dimana 1252 merupakan pasien yang terinfeksi Sars-CoV-2, dan 1229 tidak terinfeksi Sars-CoV-2. Data ini diperoleh dari rumah sakit yang berada di Brazil kota Sao Paulo. TFModel sebagai model yang dibuat dari awal telah menghasilkan performa yang cukup tinggi dengan terutama pada *evaluation metrics recall* dengan nilai sebesar 97.78%. Nilai ini merupakan nilai paling tinggi dibandingkan dengan model *pre-trained* dan xDNN.

## Referensi

- [1] Huang, C., Wang, Y., Li, X., Ren, L., Zhao, J., Hu, Y., ... & Cao, B. (2020). Clinical features of patients infected with 2019 novel coronavirus in Wuhan, China. *The lancet*, 395(10223), 497-506.
- [2] Zhu, N. et al. (2020). A novel coronavirus from patients with pneumonia in china, 2019. *New Engl. J. Medicine* .
- [3] Zhou, F. et al. (2020). Clinical course and risk factors for mortality of adult inpatients with covid-19 in wuhan, china: a retrospective cohort study. *The Lancet*.
- [4] Angelov, P., & Almeida Soares, E. (2020). SARS-CoV-2 CT-scan dataset: A large dataset of real patients CT scans for SARS-CoV-2 identification. *MedRxiv*.
- [5] Mathieu, E., Ritchie, H., Ortiz-Ospina, E. et al. (2021). A global database of COVID-19 vaccinations. *Nat Hum Behav* .
- [6] Ai, T. et al. (2020). Correlation of chest ct and rt-pcr testing in coronavirus disease 2019 (covid-19) in china: a report of 1014 cases. *Radiology* 200642.
- [7] Ng, M.-Y. et al. (2020). Imaging profile of the covid-19 infection: radiologic findings and literature review. *Radiol. Cardiothorac. Imaging* 2, e200034.
- [8] Kong, W. & Agarwal, P. P. (2020). Chest imaging appearance of covid-19 infection. *Radiol. Cardiothorac. Imaging* 2, e200028.
- [9] Valueva, M. V., Nagornov, N. N., Lyakhov, P. A., Valuev, G. V., & Chervyakov, N. I. (2020). Application of the residue number system to reduce hardware costs of the convolutional neural network implementation. *Mathematics and Computers in Simulation*, 177, 232-243.
- [10] Zhang, W. (1988, August). Shift-invariant pattern recognition neural network and its optical architecture. In *Proceedings of annual conference of the Japan Society of Applied Physics*.
- [11] Zhang, W., Itoh, K., Tanida, J., & Ichioka, Y. (1990). Parallel distributed processing model with local space-invariant interconnections and its optical architecture. *Applied optics*, 29(32), 4790-4797.
- [12] Mouton, C., Myburgh, J. C., & Davel, M. H. (2021, February). Stride and translation invariance in CNNs. In *Southern African Conference for Artificial Intelligence Research* (pp. 267-281). Springer, Cham.
- [13] Van Den Oord, A., Dieleman, S., & Schrauwen, B. (2013). Deep content-based music recommendation. In *Neural Information Processing Systems Conference (NIPS 2013)* (Vol. 26). Neural Information Processing Systems Foundation (NIPS).
- [14] Collobert, R., & Weston, J. (2008, July). A unified architecture for natural language processing: Deep neural networks with multitask learning. In *Proceedings of the 25th international conference on Machine learning* (pp. 160-167).
- [15] Avilov, O., Rimbert, S., Popov, A., & Bougrain, L. (2020, July). Deep learning techniques to improve intraoperative awareness detection from electroencephalographic signals. In *2020 42nd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC)* (pp. 142-145). IEEE.
- [16] Tsantekidis, A., Passalis, N., Tefas, A., Kannianen, J., Gabbouj, M., & Iosifidis, A. (2017, July). Forecasting stock prices from the limit order book using convolutional neural networks. In *2017 IEEE 19th Conference on Business Informatics (CBI)* (Vol. 1, pp. 7-12). IEEE.
- [17] Forsyth, D., & Ponce, J. (2012). *Computer vision: A modern approach*. Always learning.
- [18] Simonyan, K., & Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*.
- [19] Siddhartha, M., & Santra, A. (2020). COVIDLite: A depth-wise separable deep

neural network with white balance and CLAHE for detection of COVID-19. arXiv preprint arXiv:2006.13873.

- [20] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. *Advances in neural information processing systems*, 25, 1097-1105.
- [21] Simonyan, K., & Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. arXiv preprint arXiv:1409.1556.
- [22] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778).
- [23] Rastegari, M., Ordonez, V., Redmon, J., & Farhadi, A. (2016). XNOR-net: Imagenet classification using binary convolutional neural networks. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 9908 LNCS, 525–542.
- [24] Burrus, C. S., & Parks, T. W. (1985). *Convolution Algorithms*. Citeseer: New York, NY, USA.